

**SỞ GIÁO DỤC VÀ ĐÀO TẠO THÀNH PHỐ HỒ CHÍ MINH CUỘC THI
KHOA HỌC KỸ THUẬT DÀNH CHO HỌC SINH TRUNG HỌC NĂM
HỌC 2026 – 2027**

BÁO CÁO NGHIÊN CỨU

Đề tài

**ỨNG DỤNG MÔ HÌNH HỌC MÁY XẾP HẠNG KẾT HỢP BỘ LỌC
ĐIỂM VÀO LỆNH TRÊN THỊ TRƯỜNG CHỨNG KHOÁN VIỆT NAM**

Lĩnh vực: 16 – Toán học

Người thực hiện:

Phạm Huy Phong

Thành Phố Hồ Chí Minh, Tháng 10 năm 2026

TÓM TẮT DỰ ÁN

1. Tính mới

Nghiên cứu đề xuất một chuỗi quy trình nhiều bước có cấu trúc theo từng giai đoạn, cho phép phân tích và thay đổi từng bước mà không ảnh hưởng tới cấu trúc của các bước khác. Đặc biệt, quy trình gồm một bước bộ lọc giúp tách chức năng xếp hạng và quyết định giao dịch thành hai bước riêng biệt, qua đó tăng khả năng kiểm soát quá trình ra quyết định giao dịch. Các bước xếp hạng và bộ lọc đều có thể được thay đổi thành các mô hình máy học khác hoặc các quy tắc đơn giản. Ngoài ra, chuỗi quy trình được xây dựng dựa trên chiến thuật tái cấu trúc danh mục mỗi 21 phiên bằng cách lựa chọn 20 mã cổ phiếu đứng đầu bảng xếp hạng để mua. Đây vốn là một bài toán xếp hạng, do đó XGBoost-LambdaRank được lựa chọn làm mô hình chính cho bước xếp hạng.

2. Tính khoa học

Nghiên cứu sử dụng mô hình máy học XGBoost-LambdaRank để giải quyết bài toán xếp hạng cổ phiếu. Ngoài ra, kỹ thuật kiểm tra cuốn chiếu giúp mô phỏng cách huấn luyện và đánh giá mô hình máy học trong thực tế. Kết quả nghiên cứu được đánh giá ở cả cấp độ mô hình máy học và cấp độ danh mục đầu tư bằng các chỉ số như NDCG, Sharpe và mức sụt giảm lớn nhất (MDD). Nghiên cứu được thiết kế dưới dạng một thí nghiệm so sánh dựa trên dữ liệu lịch sử của thị trường chứng khoán Việt Nam. Trong đó mô hình xếp hạng và bộ lọc đầu vào của quy trình sẽ lần lượt được thay đổi trong khi các thành phần khác giữ nguyên để đánh giá ảnh hưởng của từng thành phần được thay đổi.

3. Tính thực tiễn

Nghiên cứu đưa ra một quy trình mẫu có thể hỗ trợ việc đầu tư, trong đó người dùng có thể tự viết mã nguồn để thay đổi từng thành phần dựa trên nhu cầu. Ngoài ra, nghiên cứu góp phần giới thiệu một cách tiếp cận xây dựng danh mục dựa trên thứ hạng tương đối giữa các cổ phiếu, trong đó cổ phiếu được lựa chọn dựa trên thứ hạng thay vì được xem xét một cách độc lập.

4. Tính cộng đồng

Nghiên cứu là một nguồn tham khảo cho cộng đồng các nhà đầu tư về cách xây dựng chiến lược giao dịch. Ngoài ra, nghiên cứu cũng cung cấp một khung quy trình mà những người nghiên cứu sau có thể tham khảo và phát triển thêm. Cuối cùng, nghiên cứu góp phần phổ biến cách tiếp cận xếp hạng trong đầu tư.

Mục lục

TÓM TẮT DỰ ÁN	1
1. Tính mới	1
2. Tính khoa học	1
3. Tính thực tiễn	1
4. Tính cộng đồng	1
A. LÝ DO CHỌN ĐỀ TÀI	3
B. CÂU HỎI NGHIÊN CỨU	3
C. GIẢ THUYẾT NGHIÊN CỨU	3
D. THIẾT KẾ VÀ PHƯƠNG PHÁP NGHIÊN CỨU	4
1. Tổng quát	4
2. Thu thập và xử lý dữ liệu	5
2.1. Thu thập dữ liệu	5
2.2. Kiểm tra và làm sạch dữ liệu	5
2.3. Xác định tính thanh khoản	6
2.4. Xây dựng đặc trưng	6
2.5. Xây dựng biến mục tiêu	6
2.6. Xử lý dữ liệu cuối cùng	7
3. Thiết kế chiến thuật	7
4. Huấn luyện mô hình	7
5. Bộ lọc đầu vào	8
6. Thông số của mô hình	9
7. Thiết kế kiểm định giả thuyết	9
7.1. Kiểm định giả thuyết mô hình xếp hạng	9
7.2. Kiểm định giả thuyết về bộ lọc đầu vào	9
E. TIẾN HÀNH NGHIÊN CỨU	9
1. Kết quả kiểm định giả thuyết mô hình xếp hạng	9
2. Kết quả kiểm định giả thuyết về bộ lọc đầu vào	10
3. Kết luận và hướng phát triển	10
F. TÀI LIỆU THAM KHẢO	11

A. LÝ DO CHỌN ĐỀ TÀI

Trên thế giới, đầu tư định lượng - đặc biệt là việc ứng dụng các thuật toán máy tính và học máy - ngày càng chiếm ưu thế so với các phương pháp đầu tư truyền thống [1]. Tại Việt Nam, đã có các nghiên cứu về đầu tư định lượng ở nhiều giai đoạn: từ dự đoán giá cổ phiếu [2], dự đoán bong bóng tài chính [3], tối ưu hóa danh mục đầu tư [4] và ứng dụng mô hình học tăng cường sâu vào quyết định giao dịch tự động [5]. Tuy nhiên, các nghiên cứu này tiếp cận quá trình đầu tư theo những cách khác nhau, với các mô hình có mức độ tích hợp và cơ chế ra quyết định khác nhau. Vì vậy, vẫn cần nghiên cứu các pipeline có cấu trúc rõ ràng, trong đó khả năng dự báo và xếp hạng của học máy được kết hợp với các cơ chế lọc tín hiệu và quản trị rủi ro trước khi thực thi giao dịch. Trên cơ sở đó, nghiên cứu này đề xuất một chuỗi quy trình (pipeline) nhiều bước hoàn chỉnh, kết hợp khả năng dự báo và xếp hạng của học máy với các bộ lọc quản trị rủi ro, từ đó cải thiện hiệu suất đầu tư thực tế.

Cụ thể, quy trình đề xuất bao gồm các giai đoạn nối tiếp: trích xuất đặc trưng (feature engineering), xếp hạng cổ phiếu tiềm năng bằng mô hình Learning-to-Rank (LTR), lọc tín hiệu vào lệnh theo xu hướng thị trường (entry filter), và thực thi giao dịch. Kết quả thực nghiệm trên dữ liệu thị trường Việt Nam cho thấy hệ thống giúp giảm mức sụt giảm tài sản (drawdown) và cải thiện chỉ số Sharpe.

B. CÂU HỎI NGHIÊN CỨU

Trong các mô hình được đánh giá, mô hình nào mang lại hiệu quả tốt nhất cho chiến thuật Top-K trên thị trường chứng khoán Việt Nam?

Việc áp dụng các bộ lọc điểm vào lệnh có giúp giảm drawdown và cải thiện hiệu suất điều chỉnh theo rủi ro của chiến thuật Top-K hay không?

C. GIẢ THUYẾT NGHIÊN CỨU

Việc áp dụng thuật toán XGBoost-LambdaRank (tối ưu hóa NDCG) sẽ mang lại tỷ suất Sharpe (Sharpe Ratio, trong nghiên cứu này được gọi là Sharpe và được tính với lãi suất phi rủi ro bằng 4,5%) và chỉ số NDCG cao hơn so với các phương pháp tiếp cận hồi quy sử dụng hàm mất mát sai số bình phương trung bình (MSE).

Việc tích hợp bộ lọc điểm vào lệnh vào hệ thống XGBoost-LambdaRank sẽ giúp giảm thiểu mức sụt giảm tài sản lớn nhất (Maximum Drawdown, trong nghiên cứu này được gọi là MDD) và cải thiện Sharpe so với hệ thống chỉ sử dụng mô hình xếp hạng thuần túy.


D. THIẾT KẾ VÀ PHƯƠNG PHÁP NGHIÊN CỨU

1. Tổng quát

Nghiên cứu được thiết kế dưới dạng một thí nghiệm so sánh dựa trên dữ liệu lịch sử của thị trường chứng khoán Việt Nam. Các danh mục được xây dựng theo cùng một chiến thuật Top-K và được đánh giá trên cùng phạm vi dữ liệu, trong khi mô hình xếp hạng cổ phiếu và bộ lọc đầu vào được thay đổi theo từng điều kiện thí nghiệm. Thiết kế này cho phép đánh giá riêng biệt ảnh hưởng của mô hình xếp hạng và ảnh hưởng của bộ lọc đầu vào đối với hiệu quả của chiến thuật Top-K. Các danh mục đầu tư sử dụng chiến thuật Top-K bao gồm:

- Danh mục đầu tư sử dụng mô hình sắp xếp XGBoost-Ranker (tối ưu hóa NDCG) và bộ lọc đầu vào gồm đủ 2 thành phần (từ bây giờ, trong nghiên cứu này sẽ gọi là P1).
- Hai danh mục đầu tư sử dụng mô hình sắp xếp XGBoost-Ranker (tối ưu hóa NDCG) tương ứng với từng bộ phận của bộ lọc đầu vào (từ bây giờ, trong nghiên cứu này sẽ gọi là P2 và P3).
- Danh mục đầu tư sử dụng mô hình sắp xếp XGBoost-Ranker (tối ưu hóa NDCG) và không sử dụng bộ lọc đầu vào (từ bây giờ, trong nghiên cứu này sẽ gọi là P4).
- Danh mục đầu tư sử dụng mô hình sắp xếp Hồi quy tuyến tính và không sử dụng bộ lọc đầu vào (từ bây giờ, trong nghiên cứu này sẽ gọi là P5).
- Danh mục đầu tư sử dụng mô hình sắp xếp XGBoost Regressor và không sử dụng bộ lọc đầu vào (từ bây giờ, trong nghiên cứu này sẽ gọi là P6).
- Danh mục đầu tư sử dụng mô hình sắp xếp LSTM và không sử dụng bộ lọc đầu vào (từ bây giờ, trong nghiên cứu này sẽ gọi là P7).

Trong đó, P1 là bộ khung được đề xuất trong nghiên cứu. P2 và P3 là các pipeline được sử dụng để đánh giá riêng từng thành phần của bộ lọc đầu vào. P4 là pipeline cơ sở để đánh giá ảnh hưởng của bộ lọc đầu vào. P5, P6 và P7 là các pipeline sử dụng các mô hình xếp hạng thay thế để so sánh với XGBoost-Ranker.



Hình 1. Quy trình xếp hạng và đề xuất cổ phiếu

Trong nghiên cứu, XGBoost-Ranker được sử dụng với cơ chế LambdaRank và mục tiêu tối ưu NDCG (rank:ndcg), do đó mô hình này được gọi là XGBoost-LambdaRank trong phần so sánh kết quả.

2. Thu thập và xử lý dữ liệu

2.1. Thu thập dữ liệu

Dữ liệu OHLCV của 280 cổ phiếu được thu thập tự động thông qua thư viện Python vnstock [6]. Các cổ phiếu có dữ liệu trong khoảng thời gian từ ngày 04/01/2016 đến ngày 26/03/2026 . (chi tiết xem Phụ lục 5.1. Thu thập dữ liệu).

2.2. Kiểm tra và làm sạch dữ liệu

Trong quá trình kiểm tra dữ liệu, nghiên cứu ghi nhận số lượng cổ phiếu có dữ liệu giảm đột ngột vào ngày 23/01/2018 và 24/01/2018, lần lượt còn 27 và 26 cổ phiếu, trong khi các ngày liền trước và liền sau có trên 200 cổ phiếu. Đây là hai ngày duy nhất xuất hiện mức độ thiếu hụt dữ liệu chéo giữa các cổ phiếu nghiêm trọng như vậy trước khi áp dụng bộ lọc giá trị giao dịch trung bình 21 ngày. Do đó, hai ngày này được loại khỏi bộ dữ liệu sử dụng trong nghiên cứu (chi tiết xem Phụ lục 5.2. Kiểm tra và làm sạch dữ liệu).

Đối với các hàng dữ liệu vi phạm ít nhất một quy tắc OHLC (giá thấp nhất (Low) cao hơn giá cao nhất (High), giá cao nhất (High) thấp hơn giá mở cửa (Open), giá cao nhất (High) thấp hơn giá đóng cửa (Close), giá thấp nhất (Low) cao hơn giá mở cửa (Open), giá thấp nhất (Low) cao hơn giá đóng cửa (Close), hoặc bất kỳ giá trị OHLC nào nhỏ hơn hoặc bằng 0), toàn bộ giá trị OHLC của hàng dữ

liệu vi phạm được thay thế bằng giá trị OHLC của hàng dữ liệu hợp lệ gần nhất trước đó của cùng cổ phiếu.

Đối với mỗi cổ phiếu có dữ liệu với khối lượng giao dịch (Volume) bằng 0, ngày có Volume bằng 0 gần nhất trong toàn bộ chuỗi dữ liệu được xác định làm mốc cắt. Toàn bộ dữ liệu của cổ phiếu từ ngày này trở về trước, bao gồm cả ngày có Volume bằng 0, được loại bỏ.

2.3. Xác định tính thanh khoản

Một dòng dữ liệu của một cổ phiếu được đánh dấu là kém thanh khoản nếu giá trị giao dịch trung bình của 21 phiên gần nhất trước dòng dữ liệu đó của cổ phiếu nhỏ hơn 2,5 tỷ VND.

Để đảm bảo tính liên tục của dữ liệu sử dụng trong quá trình xây dựng đặc trưng, các dòng dữ liệu được đánh dấu là kém thanh khoản không bị loại bỏ ngay khỏi chuỗi dữ liệu. Khi tính các đặc trưng yêu cầu dữ liệu theo chuỗi thời gian liên tục, các dòng dữ liệu này vẫn được sử dụng. Khi tính các đặc trưng ở cấp độ thị trường hoặc các đại lượng thống kê chéo giữa các cổ phiếu, các dòng dữ liệu kém thanh khoản không được sử dụng.

Sau khi tất cả các đặc trưng đã được xây dựng, các dòng dữ liệu kém thanh khoản bị loại bỏ.

2.4. Xây dựng đặc trưng

Tại mỗi thời điểm t , các đặc trưng đầu vào được tính toán chỉ từ thông tin thị trường đã có trước thời điểm ra quyết định, cụ thể đến ngày $t-1$, nhằm tránh hiện tượng sử dụng thông tin tương lai (look-ahead bias). Các đặc trưng bao gồm các chỉ báo kỹ thuật và các đặc trưng về giá, lợi suất, khối lượng giao dịch, thanh khoản và trạng thái thị trường (chi tiết xem Phụ lục 5.3. Xây dựng đặc trưng) [7], [8], [9], [10], [11].

2.5. Xây dựng biến mục tiêu

Biến mục tiêu được sử dụng trong nghiên cứu là lợi nhuận được điều chỉnh theo rủi ro. Cụ thể, tại thời điểm t , biến mục tiêu được tính bằng lợi nhuận log trong 21 phiên tiếp theo chia cho độ biến động trong 63 phiên gần nhất:

$$y_t = \frac{R_{t,t+21}^{log}}{\sigma_{63,t}}$$

trong đó $R_{t,t+21}^{log}$ là lợi nhuận log của cổ phiếu trong 21 phiên sau thời điểm t , còn $\sigma_{63,t}$ là độ biến động của cổ phiếu trong 63 phiên gần nhất trước thời điểm t .

Độ biến động được chuẩn hóa theo năm bằng cách nhân độ lệch chuẩn của lợi nhuận log ngày với $\sqrt{252}$. Sau đó, biến mục tiêu được chuẩn hóa theo phương pháp min-max trên phương diện chéo giữa các cổ phiếu trong từng ngày giao dịch, với giá trị sau chuẩn hóa nằm trong khoảng từ 0 đến 100.

2.6. Xử lý dữ liệu cuối cùng

Sau cùng, các dòng dữ liệu chứa giá trị NaN phát sinh trong quá trình xây dựng đặc trưng và lọc dữ liệu được loại bỏ.

3. Thiết kế chiến thuật

Vì mỗi cổ phiếu được sử dụng trong nghiên cứu phải đạt giá trị giao dịch bình quân 21 phiên gần nhất tối thiểu 2,5 tỷ VND, nghiên cứu lựa chọn $K=20$ và vốn ban đầu 500 triệu VND. Với $K=20$, giá trị phân bổ ban đầu cho mỗi cổ phiếu là 25 triệu VND, tương đương tối đa 1% giá trị giao dịch bình quân 21 phiên của cổ phiếu tại ngưỡng thanh khoản tối thiểu. Thiết lập này nhằm hạn chế tác động của quy mô giao dịch đến hiện tượng trượt giá.

Theo nghiên cứu của Robert Almgren và đồng nghiệp [12], mức trượt giá ước tính là 0,0393% đối với cổ phiếu có mức biến động giá trung bình lớn nhất trong nghiên cứu được trích dẫn. Kết quả này được sử dụng làm tham chiếu cho quy mô của tác động trượt giá. Do mức trượt giá tham chiếu tương đối nhỏ và các tham số để ước lượng được trích xuất từ một nghiên cứu khác, nghiên cứu không đưa chi phí trượt giá vào mô phỏng giao dịch.


Đợt mua cổ phiếu thứ i được thực hiện vào ngày t , đợt bán tương ứng được thực hiện vào ngày $t+21$, và đợt mua tiếp theo, $i+1$, bắt đầu vào ngày $t+24$, nhằm mô phỏng chu kỳ thanh toán $T+2$ của thị trường chứng khoán Việt Nam [13].

Kết quả giả lập đã bao gồm mức phí 0,1% trên mỗi giao dịch mua và bán, cùng với mức thuế 0,1% đối với giao dịch bán.

4. Huấn luyện mô hình

Mô hình được huấn luyện bằng phương pháp kiểm định tiến bước dạng cửa sổ trượt cố định (rolling walk-forward validation), lấy cảm hứng từ nghiên cứu của Deep và đồng nghiệp [14]. Cửa sổ huấn luyện có độ dài cố định 756 phiên giao dịch, trong đó 21 phiên cuối cùng được dành làm khoảng đệm an toàn (không được sử dụng để huấn luyện) nhằm tránh mô hình học được thông tin nhìn trước dữ liệu kiểm tra — do đó số phiên thực sự dùng để huấn luyện là 735 phiên. Ngay sau khoảng đệm là tập kiểm tra, có độ dài 184 phiên giao dịch. Ở mọi bước, tỷ lệ và tổng độ dài của ba thành phần này (huấn luyện, đệm, kiểm tra) là như nhau. Khi chuyển sang bước tiếp theo, toàn bộ cửa sổ (huấn luyện, đệm, kiểm tra) được dịch chuyển về phía trước đúng 184 phiên giao dịch — bằng với độ dài của tập kiểm tra — để đảm bảo các tập kiểm tra liên tiếp nối tiếp nhau không chồng lấp và không bỏ sót phiên giao dịch nào.

Tại mỗi bước, các đặc trưng được so sánh theo từng nhóm (tham khảo Phụ lục 5.3. Xây dựng đặc trưng) trên tập dữ liệu huấn luyện để thực hiện lọc đặc trưng. Với mỗi cặp đặc trưng có giá trị tuyệt đối của hệ số tương quan Spearman lớn hơn hoặc bằng 0,75, đặc trưng có giá trị tuyệt đối của ICIR thấp hơn sẽ bị loại bỏ [15].



Hình 2. Biểu đồ Gantt của các giai đoạn huấn luyện và kiểm định

5. Bộ lọc đầu vào

Chiến thuật Top-K cơ sở luôn phân bổ vốn để mua 20 cổ phiếu có thứ hạng cao nhất, bất kể điều kiện của thị trường. Tuy nhiên, trong những giai đoạn thị trường có xu hướng bất lợi, ngay cả các cổ phiếu được xếp hạng cao nhất vẫn có thể chịu ảnh hưởng từ rủi ro thị trường chung. Vì vậy, bộ lọc đầu vào được xây dựng nhằm hạn chế mức độ phơi nhiễm với thị trường dựa trên hai điều kiện.

Cụ thể, bộ lọc gồm hai thành phần:

Độ phân tán (P2): Điều kiện được kích hoạt khi giá trị MAD của lợi nhuận các cổ phiếu so với lợi nhuận trung bình của thị trường thuộc nhóm 25% thấp nhất (Q1) trong 252 phiên gần nhất. Điều kiện này xác định những giai đoạn thị trường có mức độ phân tán lợi nhuận tương đối thấp.

Xu hướng thị trường (P3): Điều kiện được kích hoạt khi hiệu giữa EMA21 của lợi nhuận trung bình 21 phiên và EMA63 của lợi nhuận trung bình 63 phiên, được tính trên toàn bộ các cổ phiếu thỏa mãn điều kiện về giá trị giao dịch trung bình 21 ngày, nhỏ hơn 0:

$$EMA_{21}(\bar{R}_t) - EMA_{63}(\bar{R}_t) < 0.$$

Hai thành phần P2 và P3 được xem xét với vai trò ngang nhau trong cấu trúc bộ lọc kết hợp. Bộ lọc kết hợp P1 chỉ được kích hoạt khi đồng thời cả hai điều kiện P2 và P3 được thỏa mãn. Khi P1 được kích hoạt, toàn bộ vốn được giữ ở trạng thái tiền mặt và không thực hiện giao dịch mua. Nếu không đồng thời thỏa mãn

cả hai điều kiện, P1 không làm thay đổi lượng vốn được phân bổ bởi chiến thuật Top-K cơ sở.

6. Thông số của mô hình

Do chiến thuật đầu tư chỉ lựa chọn 20 cổ phiếu có thứ hạng cao nhất để đưa vào danh mục, mô hình XGBoost-Ranker được cấu hình với các tham số liên quan đến mục tiêu xếp hạng như sau:

- `objective="rank:ndcg"`: sử dụng hàm mục tiêu dựa trên NDCG, phù hợp với bài toán xếp hạng trong đó các vị trí đầu của danh sách có ý nghĩa quan trọng đối với chiến thuật Top-K [16].
- `lambdarank_pair_method="topk"`: sử dụng phương pháp lấy mẫu cặp tập trung vào phần đầu của danh sách xếp hạng, phù hợp với chiến thuật chỉ sử dụng các cổ phiếu có thứ hạng cao nhất.
- `lambdarank_num_pair_per_sample=20`: số lượng cặp được lấy mẫu trên mỗi mẫu được thiết lập bằng 20, tương ứng với quy mô $K=20$ của danh mục.
- `ndcg_exp_gain=False`: sử dụng gain tuyến tính theo giá trị nhãn mục tiêu thay vì gain theo hàm số mũ, nhằm duy trì thông tin về độ lớn tương đối giữa các giá trị của biến mục tiêu mà không khuếch đại quá mức chênh lệch giữa các nhãn.

7. Thiết kế kiểm định giả thuyết

7.1. Kiểm định giả thuyết mô hình xếp hạng

Bốn pipeline P4, P5, P6 và P7 được đưa qua cùng chiến thuật Top-K ($K=20$) để tạo chuỗi lợi nhuận danh mục theo thời gian. Hiệu quả đầu tư của từng mô hình được đánh giá bằng tỷ suất Sharpe, trong khi chất lượng xếp hạng được đánh giá bằng chỉ số NDCG.

7.2. Kiểm định giả thuyết về bộ lọc đầu vào

P1, P2, P3 và P4 được so sánh để đánh giá tác động của bộ lọc đầu vào. Các pipeline sử dụng cùng mô hình XGBoost-Ranker và cùng chiến thuật Top-K ($K=20$), trong khi thành phần bộ lọc đầu vào được thay đổi giữa các điều kiện thí nghiệm.

E. TIẾN HÀNH NGHIÊN CỨU

1. Kết quả kiểm định giả thuyết mô hình xếp hạng

Kết quả giả lập giao dịch của 4 mô hình và không sử dụng bộ lọc đầu vào :

Mô hình	NDCG	Sharpe
XGBoost-LambdaRank (P4)	0,8998	1,0204
Hồi quy tuyến tính (P5)	0,8985	0,6356
XGBoost-Regressor (P6)	0,8971	0,4985
LSTM (P7)	0,8982	0,8115

XGBoost-LambdaRank (P4) đạt giá trị NDCG và Sharpe cao nhất trong bốn mô hình được so sánh.

2. Kết quả kiểm định giả thuyết về bộ lọc đầu vào

Bảng thể hiện Sharpe trước và sau khi áp dụng các bộ lọc:

Pipeline	MDD	Sharpe
P1	26,29%	1,1545
P2	32,29%	1,1391
P3	32,01%	0,8309
P4	42,40%	1,0204

Từ kết quả thực nghiệm, P1, sử dụng đầy đủ hai thành phần của bộ lọc đầu vào, đạt MDD thấp nhất (26,29%) và Sharpe cao nhất (1,1545) trong bốn pipeline được so sánh. Kết quả này cho thấy việc kết hợp hai thành phần của bộ lọc đầu vào có hiệu quả tích cực đối với MDD và Sharpe trong điều kiện thí nghiệm của nghiên cứu.

3. Kết luận và hướng phát triển

Nghiên cứu cho thấy XGBoost-LambdaRank đạt NDCG và Sharpe cao nhất trong các mô hình được thử nghiệm khi không sử dụng bộ lọc đầu vào. Khi được sử dụng riêng lẻ, bộ lọc độ phân tán cho kết quả tích cực đối với cả MDD và Sharpe, trong khi bộ lọc xu hướng thị trường giúp giảm MDD nhưng đồng thời làm giảm Sharpe. Khi kết hợp hai bộ lọc, P1 (Pipeline mà nghiên cứu đề xuất) đạt MDD thấp nhất và Sharpe cao nhất trong bốn pipeline được so sánh. Nghiên cứu có một số hạn chế. Thứ nhất, chiến thuật chỉ sử dụng giá đóng cửa để xác định thời điểm giao dịch và không mô phỏng chi phí trượt giá. Mặc dù nghiên cứu tham khảo mức trượt giá 0,0393% từ một nghiên cứu trước đó, mức này chưa được ước lượng trực tiếp trên dữ liệu và điều kiện giao dịch của nghiên cứu hiện tại. Do đó, kết quả mô phỏng có thể chưa phản ánh đầy đủ các yếu tố của giao dịch thực tế.

F. TÀI LIỆU THAM KHẢO

- [1] E. Cheng, “Just 10% of trading is regular stock picking, JPMorgan estimates,” CNBC. Accessed: Aug. 07, 2026. [Online]. Available: <https://www.cnbc.com/2017/06/13/death-of-the-human-investor-just-10-percent-of-trading-is-regular-stock-picking-jpmorgan-estimates.html>
- [2] H. T. Nhon, N. Do-Thi, and T. Nguyen-Trang, “Predicting stock returns using machine learning combined with data envelopment analysis and automatic feature engineering: A case study on the Vietnamese stock market,” *PLOS ONE*, vol. 20, no. 9, p. e0332154, Sep. 2025, doi: 10.1371/journal.pone.0332154.
- [3] K. L. Tran, H. A. Le, C. P. Lieu, and D. T. Nguyen, “Machine Learning to Forecast Financial Bubbles in Stock Markets: Evidence from Vietnam,” *Int. J. Financ. Stud.*, vol. 11, no. 4, p. 133, Dec. 2023, doi: 10.3390/ijfs11040133.
- [4] S. Goutte, H.-V. Le, F. Liu, and H.-J. von Mettenheim, “Mcds strategies for portfolio optimization: a case study on Vietnamese stock market dynamics,” *Ann. Oper. Res.*, vol. 353, no. 1, pp. 321–351, Oct. 2025, doi: 10.1007/s10479-025-06736-z.
- [5] H.-T. N. Nguyen, B.-N. N. Mac, A.-D. Tran, N.-T. Nguyen, and D.-T. Pham, “Deep Reinforcement Learning Approach Using Customized Technical Indicators for A Pre-emerging Market: A Case Study of Vietnamese Stock Market,” in *2022 RIVF International Conference on Computing and Communication Technologies (RIVF)*, Dec. 2022, pp. 737–742. doi: 10.1109/RIVF55975.2022.10013836.
- [6] T. Vu, *thinh-vu/vnstock*. (Apr. 30, 2026). Python. Accessed: Jun. 29, 2026. [Online]. Available: <https://github.com/thinh-vu/vnstock>
- [7] Z. Kakushadze, “101 Formulaic Alphas,” *Wilmott*, vol. 2016, no. 84, pp. 72–81, 2016, doi: 10.1002/wilm.10525.
- [8] N. Jegadeesh and S. Titman, “Returns to Buying Winners and Selling Losers: Implications for Stock Market Efficiency,” *J. Finance*, vol. 48, no. 1, pp. 65–91, 1993, doi: 10.1111/j.1540-6261.1993.tb04702.x.
- [9] E. F. Fama and K. R. French, “Multifactor Explanations of Asset Pricing Anomalies,” *J. Finance*, vol. 51, no. 1, pp. 55–84, 1996, doi: 10.1111/j.1540-6261.1996.tb05202.x.
- [10] A. Frazzini and L. H. Pedersen, “Betting against beta,” *J. Financ. Econ.*, vol. 111, no. 1, pp. 1–25, Jan. 2014, doi: 10.1016/j.jfineco.2013.10.005.
- [11] T. J. George and C.-Y. Hwang, “The 52-Week High and Momentum Investing,” *J. Finance*, vol. 59, no. 5, pp. 2145–2176, 2004, doi: 10.1111/j.1540-6261.2004.00695.x.
- [12] Emmanuel Hauptmann, Robert Almgren, Chee Thum, and Hong Li, “Direct Estimation of Equity Market Impact,” *ResearchGate*, Apr. 2005, Accessed: Aug. 07, 2026. [Online]. Available: https://www.researchgate.net/publication/228754794_Direct_Estimation_of_Equity_Market_Impact

- [13] xaydungchinh sach.chinhphu.vn, “Chu kỳ thanh toán chứng khoán chính thức rút ngắn xuống T+2,” xaydungchinh sach.chinhphu.vn. Accessed: Aug. 07, 2026. [Online]. Available: <https://xaydungchinh sach.chinhphu.vn/chu-ky-thanh-toan-chung-khoan-chinh-thuc-rut-ngan-xuong-t2-119220829211822366.htm>
- [14] G. Deep, A. Deep, and W. Lamptey, “Interpretable Hypothesis-Driven Trading: A Rigorous Walk-Forward Validation Framework for Market Microstructure Signals,” Dec. 15, 2025, *arXiv*: arXiv:2512.12924. doi: 10.48550/arXiv.2512.12924.
- [15] K. Järvelin and J. Kekäläinen, “IR evaluation methods for retrieving highly relevant documents,” *ACM SIGIR Forum*, vol. 51, no. 2, pp. 243–250, Aug. 2017, doi: 10.1145/3130348.3130374.
- [16] dmlc, “xgboost/src/common/ranking_utils.h at master · dmlc/xgboost,” GitHub. Accessed: Aug. 07, 2026. [Online]. Available: https://github.com/dmlc/xgboost/blob/master/src/common/ranking_utils.h